문헌데이터 수집·조성 보완 방법

희토류 첨가 철강의 부식전류밀도 예측을 위한 문헌 기반 데이터 준비

개정일 2026-10-22 | 첨부 수집 가이드의 구조를 참고한 후속 조성 보완 기록

1. 작성 목적과 데이터 버전

본 문서는 문헌에서 일부 조성이 누락된 경우 이를 보완해 머신러닝 입력을 준비하는 방법과 관련 선행연구를 정리한다. 첨부한 「문헌데이터_수집과정_정리.pdf」의 수집·시편 연결·단위 통일·근거 기록·그룹 검증 체계를 바탕으로, 현재 REE_AL 작업 폴더에서 실제 수행한 후속 조성 보완 절차를 기술하였다. 초기 수집부터 아래 모든 논문의 알고리즘을 구현했다는 의미는 아니다.

처리 단계	행 수 / 논문 수	의미
원래 정제 자료	304 / 48	이번 조성 보완의 입력 자료
1차 보완본	293 / 44	조성 근거가 부족한 11행 제외
개정 보완본	279 / 43	주요 B·Nb를 현재 RF 입력으로 표현하지 못하는 14행 추가 제외
총 제외	25행	부식전류·예측오차·R^2와 무관하게 판단

개정본에서 핵심 조성 C·Si·Mn·P·S·Cr·Ni·Mo·Cu·N의 빈 값 959개를 복구하거나 추정하였다. 핵심 10개 원소가 채워진 행은 161개, 부분 조성 행은 118개이고, 미확정 셀 230개는 빈칸으로 유지하였다. 기존 핵심 조성의 기입값과 부식전류 타깃은 보존하였다. 단, iScience 보충자료에서 직접 확인한 Ce 첨가 시료 8행의 RE_ppm은 명목 투입량에서 보고된 모재 Ce 함량으로 교정하고 이전 값을 기록하였다.

첨부 가이드의 266행·118열 및 119/136행 학습 후보는 다른 처리 시점의 기록이다. 이번 304행 자료와 일대일 동기화를 검증하지 않았으므로 두 집계를 합산하거나 동일 데이터셋의 수치로 혼용하지 않았다. 본 개정본의 279행은 학습 후보 보완본이며, 새 머신러닝 학습과 독립 성능 검증을 완료한 자료는 아니다.

2026-10-22 조성 보완 이력 | 열처리 조건 추가 개정: 7-10쪽 (2026-10-23)

2. 실제로 조성 결측을 보완한 머신러닝 선행연구

[1] Yan et al. (2020): 강의 부식 예측에서 조성 결측값 대입

Corrosion rate prediction and influencing factors evaluation of low-alloy steels in marine atmosphere using machine learning approach. Science and Technology of Advanced Materials 21, 359-370. DOI: 10.1080/14686996.2020.1746196.

저합금강의 대기 부식속도를 예측하면서 미보고 또는 검출한계 이하인 일부 미량 원소를 해당 원소의 데이터셋 내 최소 검출한계값으로 대입한 사례다. 조성 결측을 전처리한 뒤 회귀 모델을 구축했다는 점에서 직접적인 부식 분야 선행 사례다. 다만 검출한계 대입은 이번의 U/2 대입, 강종 대표값 또는 유사 합금 중앙값과 다른 규칙이다. 해양 대기 부식속도와 수용액의 i_corr도 서로 다른 목표값이다.

원문 확인: https://pmc.ncbi.nlm.nih.gov/articles/PMC7476538/ ; Methods의 데이터 전처리 부분.

[2] Li et al. (2025): 고강도강의 누락 조성·조직을 추정한 뒤 ML 적용

Prediction and optimization of stretch flangeability of advanced high strength steels utilizing machine learning approaches. Scientific Reports 15, 16296. DOI: 10.1038/s41598-025-00786-w.

212개 강재 조건의 문헌 자료를 모아 MICE로 누락된 조성·조직 변수를 보완하고 기계적 특성 예측에 사용하였다. C·CE·Mn·Si·Cr 등을 포함한 변수의 대치 품질을 10-fold 검증으로 비교했고, MICE 내 Ridge 회귀를 선택하였다. 조성을 추정해 ML에 사용하는 직접 사례이지만 부식 연구는 아니며, 이번 중앙값 기반 참고 시료 방식은 MICE의 재현이 아니다.

원문 확인: https://pmc.ncbi.nlm.nih.gov/articles/PMC12065822/ ; Results의 Performance evaluation for MICE, Discussion의 Data imputation and quality, Methods.

[3] Xie et al. (2025): 재료 데이터의 이웃 기반 대치와 오차 검증

Imputation of Missing Data in Materials Science through Nearest Neighbors and Iterative Predictions. Journal of Chemical Theory and Computation 21, 70-78. DOI: 10.1021/acs.jctc.4c01237. 온라인 공개 2024-12-26, 권·호 연도 2025.

재료 데이터의 결측치 대치 방법들을 비교하고 이웃 기반 반복 예측법 MatImpute를 제안하였다. 대치 오차와 분포·상관 구조의 변화를 검토하므로, 결측을 채웠다는 사실만으로 품질이 확보되지 않는다는 근거가 된다. 이번에는 이웃 정보를 활용하는 원칙을 참고했으며 MatImpute를 실행하지 않았다. 확인 범위는 저자 초록과 공개 저장소다.

확인: https://pubmed.ncbi.nlm.nih.gov/39723676/ ; 저자 코드 https://github.com/big-material/MatImpute .

3. 선행연구에서 참고한 원칙과 자체 설정

[4] Verpoort et al. (2018): 불완전 재료 데이터의 검증·추정

Materials data validation and imputation with an artificial neural network. Computational Materials Science 147, 176-185. DOI: 10.1016/j.commatsci.2018.02.002.

불완전 재료 데이터의 변수 간 관계를 이용해 결측을 추정하고 오류 후보를 원출처와 대조한 연구다. 재료 입력·물성 정보를 활용한 데이터 보완과 원자료 재확인의 배경 문헌으로 참고하였다. 이번에는 논문의 ANN이나 반복 갱신 알고리즘을 구현하지 않았다. 조성만으로 모든 미보고 값을 정확히 복원할 수 있다는 근거도 아니다.

저자 공개본: https://arxiv.org/html/1803.00133 ; 동료심사 논문 정보: https://www.repository.cam.ac.uk/handle/1810/275813 .

이번 처리	문헌과의 관계	문서에서의 표현
원문·보충표 재확인	원출처 검증 원칙과 연결 [4]	원문에서 복구한 값
누락된 조성의 수치 보완	조성 대치 후 ML 적용 사례 [1,2]	추정·대치값을 별도 관리
유사 합금의 알려진 조성 이용	이웃·변수 관계 활용 원칙 [2,3,4]	자체 정의한 참고 시료 중앙값 방식
강종 대표값·범위 중간값	제조사 자료를 활용한 프로젝트 설정	실측값이 아닌 대표값 대입
상한 U의 절반 U/2	프로젝트의 대표값 가정	실제 검출값·문헌 표준으로 주장하지 않음
참고 논문 3~5개·핵심 항목 2개	프로젝트의 실무 기준	선행논문의 최적값으로 주장하지 않음

따라서 본 작업은 "선행연구의 결측치 처리 원칙을 참고해 수행한 후속 조성 보완"으로 기술한다. "위 논문과 동일한 알고리즘을 재현하였다" 또는 "강종명으로 실제 조성을 복원하였다"라고 기술하지 않는다. 제조사 대표 조성은 해당 연구 시료의 용해 로트 분석값을 대신 증명하지 못한다.

미보고는 검출한계 이하와 다르다. 검출한계가 확인되지 않은 셀에 다른 논문의 최소 검출한계를 임의로 이전하지 않았으며, [1]의 처리 사례를 모든 미보고 원소의 0 대입 근거로 사용하지 않았다.

2026-10-22 조성 보완 이력 | 열처리 조건 추가 개정: 7-10쪽 (2026-10-23)

4. 실제 적용한 조성 보완 절차

1. 동일 시편의 본문·표·보충자료에서 직접 조성을 확인할 수 있는지 먼저 검토하였다. 수치와 함께 DOI, 시편명, 표 위치, 단위 및 대리 사용 여부를 기록하였다.

2. iScience 논문의 Table S1에 있는 모재 Cr·Ni·Mo·N을 HAZ 시료의 대리 입력으로 사용하였다. 이는 국부 편석을 반영한 HAZ 실측 조성이 아니다. <0.01 wt.%로 보고된 P·S는 상한을 보존하고 대표값 0.005를 가정하였다.

3. 동일 논문의 대응 모재가 있는 일부 RE 처리 시료는 모재 조성을 대리 사용하였다. 304·316·316L은 제조사 대표 조성, 75Cr1은 공개 조성 범위의 중간값을 사용하되 추정으로 표시하였다.

4. 원문에서 명목 배합이 명시된 경우 배합값을 보존하였다. 전체 원자 배합이 있는 경우에만 원자량으로 wt.%를 환산하였다. Fe-B9 배합은 초록의 Ce15 표기와 본문의 Cr15가 충돌하므로 실험 절·그림의 Cr15를 사용한 판단을 기록하였다.

5. 남은 핵심 원소는 같은 강종 계열의 다른 논문에 있는 기입 조성을 참고하였다. 대상과 알려진 원소가 2개 이상 겹치는 후보를 조성 거리로 정렬하였다. 알려진 Cr·Ni 수준도 함께 고려하고 논문당 하나씩 최대 5개·최소 3개 참고 시료의 중앙값을 대입하였다. 3개 논문을 확보하지 못하면 빈칸을 유지하였다.

거리 계산은 공통으로 알려진 원소의 절대 차이를 참고 자료의 사분위 범위로 나눈 값의 평균을 사용하였다. 각 원소의 참고 집단이 달라질 수 있으므로 완성된 조성 벡터가 실제로 존재하는 한 합금의 조성이라는 보장은 없다. 상한이 있는 셀의 대입값은 상한을 고려해 제한하였다. i_corr는 어떤 조성 추정에도 사용하지 않았다.

단위 환산: $w_i = 100 \times x_i M_i / \Sigma_j(x_j M_j)$, 1 wt.% = 10,000 ppm. 여기서 x는 원자 비율, M은 원자량이다. Fe가 나머지라는 명시와 기타 원소 정보가 충분하지 않으면 Fe를 단순 차감해 만들지 않았다.

추정 신뢰도는 방법의 성격을 설명하는 정성적 표시다. 참고값의 최소·최대는 자료의 분포이며, 95% 신뢰구간이 아니다. 핵심 10개 조성이 채워졌다는 표시는 모든 원소의 질량수지가 확인됐거나 모두 실측됐다는 뜻이 아니다.

2026-10-22 조성 보완 이력 | 열처리 조건 추가 개정: 7-10쪽 (2026-10-23)

5. 0값 정정과 최종 포함·제외

Fe-Nb-B-Dy/Tb 계열 14행은 주요 조성이 B·Nb·Fe 등에 있지만 현재 RF 입력에는 B·Nb가 없다. 앞선 보완본에서 명목 배합에 없는 C·Si·Mn·P·S·Cr·Ni·Mo·Cu·N을 0으로 표현한 것은 해당 원소의 실측 부재를 확인한 결과가 아니었다. 개정 단계에서 이 140개 명목 0 대입을 철회하고, 미보고 핵심 조성을 빈칸으로 복원한 뒤 14행을 현재 모델용 보완본에서 제외하였다.

기존에 근거가 부족해 제외한 11행과 합쳐 최종 제외는 25행이다. 추가 원소의 배합 정보를 가진 자료도 현재 모델에서 주요 조성을 표현하지 못하면 제외할 수 있다. 제외된 자료는 잘못된 실험이라는 의미가 아니며, 향후 B·Nb 입력을 포함한 별도 모델에서는 재검토할 수 있다. 제외 목록과 그 사유는 보존하였다.

6. 데이터 준비와 머신러닝 검증의 구분

현재 저장된 RF는 기존 304행 자료에 기반한 모델이다. 기존 논문 단위 holdout 3개 분할에서 log10(i_corr)의 평균 R^2는 약 0.0374였으며, 이는 개발 과정에서 반복 사용한 분할의 결과다. 이 점수를 새 279행 조성 보완본의 성능으로 인용하지 않는다. 이번 조성 보완과 문헌 검토에서는 새 학습·검증을 수행하지 않았다.

유사 합금 대치의 현재 파일은 열람·검토용으로 전체 입력 조성 자료를 참고해 생성했다. 독립 평가에서는 원래의 결측 자료를 논문 단위로 먼저 나누고, 참고 시료 선택과 거리 척도의 추정을 학습 분할 안에서 수행해야 한다. 테스트 논문의 조성이나 타깃을 대치기 학습에 사용하지 않는다. 최종 테스트를 반복 확인해 제외 기준을 바꾸는 방식도 피한다.

후속 검증에서는 원문 기반 자료만 사용한 경우와 대표값·통계 대치를 허용한 경우를 같은 그룹 분할에서 비교한다. 추가로 알려진 조성을 일부 가린 뒤 복원 오차를 점검하고, 강종별·논문별 오차와 대치 비율을 함께 보고한다. 이는 아직 실행하지 않은 검증 계획이다. R^2 0.5 달성이나 대치 후 성능 향상을 가정하지 않는다.

7. 원문 수집 가이드와의 연결

한 행은 시편·재료 상태·시험 조건의 조합으로 보고, 동일 시편의 조성과 i_corr를 연결한다. 투입량과 잔류 조성, OCP 시간과 침지·주사 시간, 정성적 상 정보와 실측 분율을 구분하는 원 가이드의 원칙을 유지한다. 현재 문서는 조성 보완을 다루며 pH·OCP·상 분율을 새로 계산하거나 원 가이드의 모든 API 수집 절차를 재실행한 보고서는 아니다.

2026-10-22 조성 보완 이력 | 열처리 조건 추가 개정: 7-10쪽 (2026-10-23)

8. 논문 Methods에 사용할 수 있는 기술문

희토류 첨가 철강의 부식전류밀도 예측을 위한 문헌 기반 데이터셋을 준비하였다. 동일 시편의 조성·재료 상태·전기화학 조건을 목표값과 연결하고, 보고 단위를 통일한 뒤 출처와 검토 기록을 보존하였다. 후속 조성 보완에서는 강의 부식 예측에서 조성 결측을 수치 대입한 사례 [1], 고강도강의 조성·조직 결측을 추정해 머신러닝에 사용한 사례 [2], 재료 데이터의 이웃 기반 대치 및 원출처 검증 연구 [3,4]를 참고하였다. 이들 연구의 알고리즘을 그대로 재현하는 대신, 원문 복구를 우선하고 근거 수준을 구분하는 단계적 보완 규칙을 적용하였다.

직접 보고된 조성을 우선 사용하였으며, 미보고 항목은 보충자료, 동일 논문의 대응 모재, 제조사 강종 대표값 또는 명시적 명목 배합으로 보완하였다. 범위만 확인된 일부 항목에는 중간값을 대표값으로 사용하였다. 남은 항목은 같은 강종 계열에서 알려진 조성이 겹치는 서로 다른 3~5개 논문의 참고 시료를 선택하고 원소별 중앙값으로 대치하였다. 이 수와 거리 계산 규칙은 본 프로젝트의 설정이다. 모든 추정값을 원래 기입값과 구분하고 방법·출처·참고 범위를 기록하였으며, 조성 추정에는 부식전류값을 사용하지 않았다.

미보고 조성을 일괄 0으로 간주하지 않았다. 조성 근거가 부족한 관측과 주요 조성을 현재 입력 변수로 표현할 수 없는 관측을 제외하여 304개 관측 중 279개 관측을 후속 분석 후보로 유지하였다. 핵심 조성의 기존 기입값과 목표 부식전류는 보존하였다. 보완본은 추정이 포함된 데이터 준비 결과이며, 대치 후 모델 성능 향상은 아직 검증하지 않았다. 독립 평가 시에는 원래 결측 자료를 논문 단위로 분할한 후 학습 분할에서만 통계적 대치를 수행한다.

9. 재현 자료와 참고문헌

데이터: best_model/data/composition_estimated.csv 및 composition_estimated_revised.xlsx. 원래 데이터·셀별 근거·제외 목록은 XLSX의 ORIGINAL_DATA, ESTIMATION_LOG, EXCLUDED_ROWS 시트에 보존했다. 재생성 코드는 best_model/estimate_composition.py, 집계·해시는 composition_review/summary.json에 있다. 부속 설명은 COMPOSITION_NOTES.md에 있다.

[1] Yan L., Diao Y., Lang Z., Gao K. (2020). Science and Technology of Advanced Materials 21, 359-370. https://doi.org/10.1080/14686996.2020.1746196

[2] Li T., Yang Z., Cui J., Chen W., Almatani R., Wu Y. (2025). Scientific Reports 15, 16296. https://doi.org/10.1038/s41598-025-00786-w

[3] Xie C., Li R., Li Y., Xie H., Liu Q. (2025). Journal of Chemical Theory and Computation 21, 70-78. https://doi.org/10.1021/acs.jctc.4c01237

[4] Verpoort P. C., MacDonald P., Conduit G. J. (2018). Computational Materials Science 147, 176-185. https://doi.org/10.1016/j.commatsci.2018.02.002

10. 열처리 온도·시간의 문헌 수집 방법

추가 개정 2026-10-23. 앞 1-6쪽은 2026-10-22 조성 보완 이력으로 보존한다. 5쪽의 RF 및 과거 R^2는 개발 당시 기록이며, 현재 확장 CSV의 학습·검증 결과가 아니다. 이번 추가 절은 사전에 정할 수 있는 열처리 입력을 실제로 수집한 방법을 설명한다.

10.1 피처의 정의와 수집 대상

공정 입력은 **heat_treatment_temperature_C**(유지 온도, ℃)와 **heat_treatment_time_min**(해당 온도에서의 유지시간, min) 두 항목으로 한정하였다. 동일 시편의 조성, 재료 상태, 계획된 전기화학 시험조건과 i_corr를 연결한다. 결정립 크기·측정 상분율은 제조 전 입력에서 제외하였다.

10.2 원문에서 값을 회수하는 순서

① **시편 식별:** DOI, 시편명, 처리 상태, 전해질·시험온도·침지 조건으로 한 행을 식별한다. 같은 논문의 다른 시편이나 다른 부식시험 조건을 섞지 않는다.

② **원출처 확인:** Experimental/Materials and Methods의 처리 설명, 열처리 표, 보충자료, 수치가 명시된 공정도·캡션을 대조한다. 승온 종료 온도만으로 유지 온도·시간을 만들어 넣지 않는다.

③ **온도-시간 쌍 연결:** 동일한 등온 유지단계의 두 값을 함께 기록한다. 용체화 온도와 시효 시간을 조합하거나, 시험온도와 열처리 시간을 연결하지 않는다.

④ **시편별 분기:** 공통 처리와 시편별 변경 조건을 구분한다. "모든 시편에 적용"이라는 근거가 있을 때만 공통 조건을 여러 행에 연결한다.

⑤ **단위 통일·검증:** 원래 수치·단위와 환산식을 남기고 ℃ 및 min으로 통일한다. API 추출값은 원문 인용문과 시편 연결을 재검토한다. 구체적인 감사 기록은 12절에 정리하였다.

보고 형식	기록 방법
1 h / 4 h / 2 s	60 min / 240 min / 0.03333 min으로 환산
482 ± 3 ℃	명시된 중심 설정값 482 ℃를 기록하고 ±3 ℃ 허용범위를 근거에 보존
온도 또는 유지시간 미보고	해당 항목은 결측으로 유지. 미처리를 0 ℃·0 min으로 대입하지 않음

조성 보완과의 차이: 다른 논문의 중앙값, 제조사 강종 대표값, 조성 유사도 또는 i_corr로 열처리 온도·시간을 추정하지 않았다. 범위만 있고 대표 설정값이 없는 열처리 조건도 임의의 중간값으로 완성하지 않는다.

11. 다단계 열처리의 기록 기준과 예시

다단계 이력을 온도·시간 두 숫자로 모두 표현할 수는 없다. **이번 신규 추출은 마지막으로 명시된 등온 유지단계를 기본으로 선택**하고, 이전 단계는 heat_history_note에 남겼다. 기존 자료는 앞서 확인한 대표 단계를 보존했으므로 용체화·시효·빌릿 재가열·소결이 섞여 있다. 현재 CSV가 하나의 동일한 처리단계로 통일됐다는 뜻은 아니다.

시편 / 출처	온도 (℃)	시간 (min)	선택한 단계와 보존한 이력
SASS T30 [5]	1200	30	기존 자료의 용체화 단계. 이후 수냉 → 900 ℃/30 min 시효 → 공랭 이력을 별도 보존.
17-4PH A480 [6]	480	60	최종 시효 단계. 선행 1040 ℃/60 min 용체화 및 수냉은 이력으로 기록.
17-4PH F620 [6]	620	240	최종 시효 단계. 4 h를 240 min으로 환산.
H13 Q / YQ [7]	1080	30	담금질 전 유지. 이후 유냉. 뜨임을 거친 QT/YQT와 구분.
H13 QT / YQT [7]	580	120	최종 뜨임. 앞선 1080 ℃/30 min 유지 및 유냉 이력을 보존.
A100 steel [8]	482	360	최종 뜨임. 원문 설정값 (482 ± 3) ℃/6 h. 앞선 담금질·심냉 이력은 별도 기록.

11.1 입력과 감사 메타데이터를 구분

heat_treatment_stage는 어떤 단계의 쌍을 택했는지, **heat_history_note**는 선행 처리와 냉각 이력을 설명한다. 이 컬럼들은 감사·층화용 메타데이터이며 현재 모델의 추가 공정 피처가 아니다. 다단계 이력의 일부만 입력에 반영된 경우 thermal_history_incomplete도 확인한다.

11.2 포함·보류의 경계

시험 중 용액 온도, OCP 안정화 시간, 부식 침지시간, 세척·건조시간은 열처리 유지조건과 구분한다. 승온속도·냉각속도·자연 발생한 용접 최고온도만으로 유지시간을 추정하지 않는다. 명시적 온도와 유지시간이 있는 제어된 Gleeble 모사 열사이클은 후보가 될 수 있지만, 대응 i_corr의 단위·시편 연결까지 확인해야 포함한다.

실제로 [9]의 CGHAZ는 1320 ℃에서 2 s 유지한 조건이 확인되었다. 그러나 Table 4의 전류 단위가 A·cm²로 표기되어 재검토에서 보류하였다. 열처리 두 값의 확보만으로 해당 부식행의 타당성이 자동 확보되지는 않는다.

AL 적용 범위: 온도·시간 두 피처를 사용할 때는 같은 강종, 같은 처리단계, 같은 선행 이력과 부식환경으로 범위를 좁히는 것이 바람직하다. 서로 다른 제조 이력을 두 숫자만으로 구별하거나, 관찰된 상관관계를 열처리의 독립적인 인과효과로 해석하지 않는다.

12. API 검증·출처 기록과 현재 집계

12.1 실제 수행한 검증 흐름

설정된 API 키를 사용해 문헌 메타데이터와 접근 가능한 원문을 조회하고, 이미 확보한 원문 및 공개 PDF도 함께 활용하였다. Elsevier 검색 API는 사용했으나 일부 원문은 접근 거부되었고 Springer API도 접근 제한이 있었다. 원문을 확보하지 못한 논문의 수치를 추측해 추가하지 않았다.

OpenAI API로 원문을 구조화하고, **인용문이 확보한 원문 블록에 그대로 존재하는지 코드로 확인**하였다. 이어 별도 모델 호출로 시편명, 열처리 단계, 온도·시간, 전류밀도 열과 단위 환산을 재검토하였다. 이는 API 보조 검증으로, 사람이 모든 원문을 독립적으로 검토했다거나 오류율 0%를 입증했다는 뜻은 아니다.

i_corr는 실험에서 보고된 Tafel/동전위분극 전류밀도를 우선하였다. 표와 본문에 명시된 수치는 허용했지만 그래프를 보고 임의의 숫자를 만들지 않았다. 예를 들어 [7]의 Q/YQ/QT/YQT 수치는 PDF 10쪽 본문에 직접 보고되어 있다. 부식률·부동태전류·공식전류 및 단위가 불명확한 후보는 별도로 보류하였다.

12.2 보존한 근거

record_id, source_paper_id, 시편명, 출처 URL, 원문 위치, 짧은 인용문, 원래 단위와 환산계수, 선택한 처리단계, 시편 대응 판단, 포함·보류 사유를 보존하였다. 새 값은 new_source_provenance.csv, 보류 후보는 rejected_or_unresolved.csv, 입력 목록은 feature_schema.json에서 확인할 수 있다.

집계 항목 (2026-10-23)	확인된 결과
데이터 확장 이력	45행 → 142행 → 179행
현재 전체 검토본	179행 / 39개 출처
i_corr와 열처리 온도·시간 확인	160행. 다른 조성·시험조건의 결측은 남아 있음
온도·시간 각각의 결측	19/179행, 10.61%
핵심 조성 10개 + 주요 시험조건 충족	56행 / 11개 출처. 조성 추정 포함; 모든 피처 완비를 뜻하지 않음
현재 남은 주요 결측	N: 81/179 (45.25%), pH: 157/179 (87.71%)

이번 마지막 추가분은 7개 출처의 37행이다. 이 중 Y 첨가 H13강 2행은 원문의 0.014 wt.%를 140 ppm으로 환산했다. 원문의 nominal 표기를 제조 후 잔류량 실측으로 단정하지 않는다. La·Ce·Y의 미보고 함량을 일괄 0으로 채우지 않았다.

검증 범위: 기존 142행의 i_corr를 보존했고, 논문 단위 5개 분할에서 검증 논문이 조성 donor와 IQR 산정에 들어가지 않도록 확인했다. 이는 데이터 준비 검증이며 새 모델 성능 평가 또는 실제 AL 실험 수행 결과가 아니다. 운영 학습자료와 모델은 재학습하지 않았다.

13. Methods 기술문·재현 자료

13.1 논문에 사용할 수 있는 열처리 수집 기술문

제조 전에 설정할 수 있는 공정변수로 열처리 유지 온도와 유지시간을 선정하였다. 각 문헌의 실험 방법, 열처리 표 및 보충자료에서 동일 시편의 온도-시간 쌍을 회수하고, 조성·재료 상태·전기화학 시험조건 및 부식전류밀도와 연결하였다. 온도와 시간은 각각 ℃와 min으로 통일하였으며, 원래 수치·단위와 환산 근거를 보존하였다. 열처리 온도·시간이 보고되지 않은 경우 다른 문헌이나 조성 유사도에 기반해 대치하지 않고 결측으로 유지하였다.

다단계 열처리에서는 신규 추출 자료의 마지막 명시적 등온 유지단계를 대표 입력으로 선택하고, 선행 처리와 냉각 이력 및 선택한 단계는 감사용 메타데이터로 기록하였다. 기존 자료에 보존된 대표 단계는 별도로 구분하였으며, 모든 관측이 동일한 열처리 단계에 해당한다고 가정하지 않았다. API를 이용한 구조화 결과는 원문 인용문 존재 여부와 시편·단위 대응을 재검토하였다. 미확정 타깃·단위 또는 열처리 대응 관계를 가진 관측은 학습 후보에서 보류하였다.

조성의 통계적 보완을 허용한 파일은 검토용으로 구분하였다. 독립 모델 평가에서는 논문 단위로 자료를 분리한 뒤 학습 분할에서만 조성 대치기와 척도를 산정한다. 열처리 온도·시간 및 i_corr 자체에는 통계적 대치를 적용하지 않는다. 현재 자료 준비 결과를 대치 후 성능 향상이나 능동학습 최적화의 실증 결과로 해석하지 않는다.

13.2 추가 근거 문헌

[5] 용체화 시간·온도를 변화시킨 SASS 부식시험 (2022).
https://doi.org/10.3390/ma15248780

[6] 17-4PH강 시효 처리와 부식거동 (2025).
https://doi.org/10.3390/ma18081823

[7] Y 첨가 H13강의 담금질·뜨임과 부식거동 (2025).
https://doi.org/10.3390/met15090935

[8] A100강의 초기 염무-SO2 부식거동; 482 ± 3 ℃ 뜨임.
https://doi.org/10.1039/d5ra08480f

[9] Zr-Ti-Al-RE 탈산 HSLA강의 CGHAZ 부식시험 (2023).
https://doi.org/10.3390/ma16020876

13.3 파일과 재현 경로

현재 결과 폴더: **data/al_heat_expanded_round2_20261023/**
전체 검토본: al_labeled_heat_treatment_expanded.csv
타깃·열처리 확인본: al_heat_checked_labels.csv
이번 추가분: new_rows_this_round.csv
원문 대조·조성 이력: new_source_provenance.csv / composition_imputation_log.csv
집계·결측·검증: summary.json / missingness.csv / validation.json

수집·재검토 코드는 scripts/collect_more_heat_papers.py, recover_yttrium_text_targets.py, review_heat_expansion.py에 있고, 누적 결과 생성은 build_heat_expansion.py --round2로 수행했다. 전체 검토본의 조성 대치값을 독립 평가에 그대로 재사용하지 않고, paper_group_fold_*.csv의 분할별 보완 이력을 확인한다.